Bernoulli Task 2

最新 calibration

利用 disagreement 次数构造 reference 误差界

存档版：2026-10-04（America/New_York） | 不增加 α_ρ

本次变更。 保留原来的 logit 模型、reference 概率平均、三个 logit 假设，以及 τ 的上置信界 $U_{\tau,\gamma}$。把原来的 Bernstein/Bennett 浓缩半径，替换为由 evaluation disagreement 次数归一化的二阶矩半径。τ **的校准步骤本身不变。**

比较对象与 reference

固定训练好的模型及阈值 t，比较二元决策 $\hat{Y}_A$ 与 Y_B。reference 继续使用概率，不做阈值化：

$$\hat{Y}_A(x) = \mathbf{1}\{\hat{\mu}_A(x) \geq t\}, \qquad \hat{\mu}_R(x) = \frac{1}{K}\sum_{r\in R}\hat{\mu}_r(x). \tag{1}$$

对任意概率 reference f，定义 $\Delta_f = \mathbb{E}[(\hat{Y}_A - f)^2 - (Y_B - f)^2]$；记 $\Delta_{\widehat{R}} = \Delta_{\hat{\mu}_R}$、$\Delta^* = \Delta_{\mu^*}$。正值表示模型的损失大于 B。Task 2 要认证二者方向相同，即 $\Delta_{\widehat{R}}\Delta^* > 0$。

最终可实现的公式

在 $D_1 = \{(X_i, Y_{B,i})\}_{i=1}^m$（$m \geq 2$）上，计算

$$Z_i = (\hat{Y}_A(X_i) - Y_{B,i})\{1 - 2\hat{\mu}_R(X_i)\}, \qquad \widehat{\Delta}_{\widehat{R}} = \frac{1}{m}\sum_i Z_i, \tag{2}$$

$$\widehat{\mathsf{se}} = \sqrt{\frac{\sum_i (Z_i - \widehat{\Delta}_{\widehat{R}})^2}{m(m-1)}}, \qquad N = \sum_i \mathbf{1}\{\hat{Y}_A(X_i) \neq Y_{B,i}\}. \tag{3}$$

以下简写 $U = U_{\tau,\gamma}$，并定义

$$\widetilde{\rho} = \frac{N+1}{m+1}, \qquad a(U) = \frac{\sqrt{3}}{36}\kappa U^2. \tag{4}$$

新版拒绝条件

$$\boxed{|\widehat{\Delta}_{\widehat{R}}| - t_{m-1,\,1-\alpha_\Delta/2}\widehat{\mathsf{se}} > 2a(U) + \frac{U}{2}\sqrt{\frac{\kappa(N+1)}{K(m+1)\alpha_g}}} \tag{5}$$

预先固定 $\alpha_\Delta, \alpha_g, \gamma > 0$，使其和不超过 α_{total}。**不需要新增** α_ρ。$t_{m-1,1-\alpha_\Delta/2}$ 为 Student-t 分位数；此处用于渐近区间。

阅读顺序：第 2 页列出假设；第 3 页给出不变的 τ 校准；第 4 页证明新界；第 5 页比较各版本；第 6 页说明完整保证与实验修改。

1 模型与假设

最新半径并未删除原来的三个 logit 假设

基础模型与采样设计

设 $\sigma(u) = (1 + e^{-u})^{-1}$，$K > 1$。reference identities 为 iid，且与 A、B 不重合：

$$\mu_r(x) = \sigma\{\text{logit}\,\mu^*(x) + b_r(x)\}, \qquad \mathbb{E}_r b_r(x) = 0, \qquad Y_B \mid X \sim \text{Bernoulli}(\mu_B(X)). \tag{6}$$

所有跨 reference 的概率陈述，均条件于固定的 A、B，以及已训练好的 $\hat{Y}_A$ 和已冻结的阈值。reference identities 及其真实偏差函数独立于这些拟合／选择信息和 fresh iid evaluation set D_1。D_1 对参与评估的所有模型均为 out of sample。

原来的三个 logit 假设：全部保留

1. **Centered logit error**

$$\mathbb{E}_X[\text{logit}\,\hat{\mu}_r(X) - \text{logit}\,\mu_r(X)] = 0. \tag{7}$$

   使 surrogate 的平均 logit 对比对应真实 $C_r - C_1$，支撑第 3 页的校准。它是该一阶段均值条件的充分条件。

2. **Gaussian logit offsets**

$$C_r := \mathbb{E}_X b_r(X), \qquad C_r \overset{\text{iid}}{\sim} N(0, \tau^2). \tag{8}$$

   用于 τ 的卡方校准。**不假设 g_r 正态。**

3. **Bounded item-dependent variation**

$$\mathbb{E}_r\,\text{Var}_X(b_r(X)) \le (\kappa - 1)\tau^2, \qquad \kappa \ge 1. \tag{9}$$

   因此 $\mathbb{E}_r \mathbb{E}_X b_r(X)^2 \le \kappa\tau^2$，用于曲率项和方差界。$\kappa$ 仍是预先指定的 sensitivity parameter。

概率尺度的正交条件：同样保留

令 $h_R = K^{-1}\sum_r(\hat{\mu}_r - \mu_r)$。需要原修订框架中的条件

$$\mathbb{E}[h_R(X)\{\hat{Y}_A(X) - Y_B(X)\}] = 0. \tag{10}$$

这里期望对新的 evaluation observation 取；该条件对所实现的 panel 和已拟合 reference 成立（几乎处处），而不只是训练随机性平均后成立。由此

$$\begin{aligned} g_r &:= \mathbb{E}_X[(\mu_r - \mu^*)(\hat{Y}_A - \mu_B)], \\ g_{\widehat{R}} &:= \mathbb{E}[(\hat{\mu}_R - \mu^*)(\hat{Y}_A - Y_B)] = \frac{1}{K}\sum_r g_r, \qquad \Delta_{\widehat{R}} - \Delta^* = -2g_{\widehat{R}}. \end{aligned} \tag{11}$$

Centered logit error 不自动推出式 (10)。独立 validation 选择阈值仍允许，但不能使用 D_1 或同一 reference panel 来选阈值；这些是已有设计要求。D_1 与校准集 D_2 无需彼此独立。

2 τ 的校准：沿用原方案

先得到 $U_{\tau,\gamma}$，再将其代入新的 reference 误差界

设 $n = |D_2| \geq 2$。对 $r = 2, \ldots, K$，在 D_2 上计算带符号的 logit 对比

$$z_{i,r} = \operatorname{logit} \hat{\mu}_r(X_i) - \operatorname{logit} \hat{\mu}_1(X_i), \qquad w_r = \frac{1}{n} \sum_{i \in D_2} z_{i,r}. \tag{12}$$

令 $z_i = (z_{i,2}, \ldots, z_{i,K})^\top$、$w = n^{-1} \sum_i z_i$，并取 item 层面的样本协方差

$$\widehat{\Omega} = \frac{1}{n-1} \sum_{i \in D_2} (z_i - w)(z_i - w)^\top. \tag{13}$$

Gaussian offsets 给出 $\operatorname{Var}(C_r - C_1) = 2\tau^2$、$\operatorname{Cov}(C_r - C_1, C_s - C_1) = \tau^2$（$r \neq s$）。因此，对候选 $u \geq 0$ 定义

$$\widehat{V}(u) = u^2 (I + \mathbf{1}\mathbf{1}^\top) + \frac{\widehat{\Omega}}{n}, \qquad Q(u) = w^\top \widehat{V}(u)^{-1} w, \tag{14}$$

其中 I 为 $(K-1) \times (K-1)$ 单位矩阵。记 $q_{\gamma, K-1}$ 为 χ^2_{K-1} 的**下侧 γ 分位数**：

$$\boxed{U_{\tau,\gamma} = \sup\{u \geq 0 : Q(u) \geq q_{\gamma, K-1}\}.} \tag{15}$$

若集合为空，定义 $U_{\tau,\gamma} = 0$。在原校准正则条件下，固定 K、$n \to \infty$ 时

$$\mathbb{P}(\tau \leq U_{\tau,\gamma}) \geq 1 - \gamma - o(1). \tag{16}$$

该步骤仍然需要的正则条件

1. $0 < \hat{\mu}_r(X_i) < 1$，且 D_2 对 reference 模型为 out of sample。若使用数值 clipping，其影响必须满足下面的一阶段条件。
2. 保证平均 logit 对比足够准确：

$$\mathbb{E}_X[\operatorname{logit} \hat{\mu}_r(X) - \operatorname{logit} \hat{\mu}_1(X)] = C_r - C_1 + o_p(n^{-1/2}). \tag{17}$$

   第 2 页的 exact centered logit error 使这里的均值误差为零；它不替代其余正则条件。
3. item 对比满足原来的有限维 CLT，$\widehat{\Omega}$ 一致估计相应协方差，且被求逆的矩阵非奇异。若训练不确定性在所用近似尺度上不可忽略，应按原方案纳入协方差。

原卡方论证使用 $Q(\tau) \Rightarrow \chi^2_{K-1}$ 及 $Q(u)$ 的单调性。$\tau = 0$ 时，由 $U \geq 0$，覆盖事件本身自动成立；对端点的数值计算仍须妥善处理奇异矩阵。

实施上不改的两点

先对每个 signed logit contrast 求平均，再做跨 annotator 的校准；不把逐点绝对值、RMS 或分位数代入 w。式 (15) 中使用下侧 γ 分位数，而不是 $1 - \gamma$ 分位数。

3 新 reference 界的完整证明

二阶矩控制 + 二项分布倒数恒等式；这一部分是有限样本的

第一步：用 disagreement 收紧方差。 记

$$d(X) = \hat{Y}_A(X) - \mu_B(X), \qquad \rho = \mathbb{P}(\hat{Y}_A \neq Y_B) = \mathbb{E}_X|d(X)|. \tag{18}$$

最后一个等号依赖 $\hat{Y}_A \in \{0,1\}$；并且 $d^2 \le |d|$。由 sigmoid 的 $1/4$-Lipschitz 性和 Cauchy–Schwarz，

$$\begin{aligned}\mathrm{Var}_r(g_r) &\le \mathbb{E}_r g_r^2 \le \mathbb{E}_r\mathbb{E}_X[(\mu_r - \mu^*)^2]\,\mathbb{E}_X[d^2] \\ &\le \frac{\kappa\tau^2\rho}{16}.\end{aligned} \tag{19}$$

同时，对 sigmoid 作二阶 Taylor 展开，利用 $\mathbb{E}_r b_r(x) = 0$ 和 $\sup_u |\sigma''(u)| = \sqrt{3}/18$，得到

$$|\mathbb{E}_r g_r| \le \frac{\sqrt{3}}{36}\mathbb{E}_X\left[\mathbb{E}_r[b_r(X)^2]|d(X)|\right] \le a(\tau) = \frac{\sqrt{3}}{36}\kappa\tau^2. \tag{20}$$

第二步：直接使用观测到的 N。 令 $S = K^{-1}\sum_r g_r - \mathbb{E}_r g_r$。由 iid references 和独立 evaluation 设计，

$$\mathbb{E}S^2 \le \frac{\kappa\tau^2\rho}{16K}, \qquad N \sim \mathrm{Bin}(m,\rho), \qquad S \perp N. \tag{21}$$

S 只包含真实 reference 函数；N 只包含固定二元模型与 fresh B 标签。对 $\rho > 0$，

$$\begin{aligned}\mathbb{E}\frac{1}{N+1} &= \int_0^1 \mathbb{E}[t^N]\,dt = \int_0^1 (1-\rho+\rho t)^m\,dt \\ &= \frac{1-(1-\rho)^{m+1}}{(m+1)\rho}, \quad \Longrightarrow \quad \mathbb{E}\frac{\rho}{\widetilde{\rho}} = 1-(1-\rho)^{m+1} \le 1.\end{aligned} \tag{22}$$

因此独立性给出 $\mathbb{E}[S^2/\widetilde{\rho}] \le \kappa\tau^2/(16K)$。Markov 不等式立即推出

$$\mathbb{P}\left\{|S| > \frac{\tau}{4}\sqrt{\frac{\kappa\widetilde{\rho}}{K\alpha_g}}\right\} \le \alpha_g. \tag{23}$$

若 $\rho = 0$ 或 $\tau = 0$，则相应 $g_r = 0$ 几乎处处，结论直接成立。

第三步：加回均值并代入 U。 结合式 (20)、(23)，以及 $a(u)$ 和半径对 u 的单调性，

$$\boxed{\mathbb{P}\left\{|g_{\widehat{R}}| > a(U) + \frac{U}{4}\sqrt{\frac{\kappa\widetilde{\rho}}{K\alpha_g}}\right\} \le \alpha_g + \gamma + o(1).} \tag{24}$$

关键区别： $\widetilde{\rho}$ 无须是 ρ 的上界。保证来自倒数的期望恒等式，因此不消耗 α_ρ。U 可以与 S, N 相关；代入时仅对事件 $\{\tau > U\}$ 作 union bound，不声称条件于 $\tau \le U$ 后仍有原来的尾概率。

4 与之前版本的区别

统一比较 reference 误差界：$|g_{\widehat{R}}| \le a(U) +$ 半径

曲率项 $a(U) = \sqrt{3}\kappa U^2/36$ 在下列版本中相同。为展示旧公式，本页临时记

$$v_U = \min\left\{\frac{\kappa U^2}{16}, \frac{1}{4}\right\}, \qquad L = \log(2/\alpha_g), \qquad H(z) = (1+z)\log(1+z) - z.$$

原 Bernstein 版本

$$r_{\mathrm{Ber}}(U) = \sqrt{\frac{2v_U L}{K}} + \frac{L}{3K}. \tag{25}$$

使用 centered range ≤ 1 及方差上界。显式包含 $\log(2/\alpha_g)/(3K)$；当异质性很小时，这一项仍可能主导门槛。

此前的 Bennett／Chebyshev 改进

$$r_{\mathrm{Ben}}(U) = v_U H^{-1}\left(\frac{L}{Kv_U}\right), \qquad r_{\mathrm{Cheb}}(U) = \sqrt{\frac{v_U}{K\alpha_g}}. \tag{26}$$

当 $v_U = 0$ 时半径取零。此前可使用 $\min\{r_{\mathrm{Ben}}, r_{\mathrm{Cheb}}\}$：在真实固定参数处，两者控制的是同一个绝对偏差，随后通过对 U 的单调性代入。它们尚未利用实际 disagreement 次数。

此前的 ρ_U 版本

先构造 $\mathbb{P}(\rho \le \rho_U) \ge 1 - \alpha_\rho$ 的上界，再令

$$v_{\rho,U} = \min\left\{\frac{\rho_U \kappa U^2}{16}, \frac{\rho_U^2}{4}\right\}. \tag{27}$$

相应 Chebyshev 半径为 $\sqrt{v_{\rho,U}/(K\alpha_g)}$；也可在同一参数上使用 range 为 ρ_U 的 Bennett 界。这条路线需要总预算 $\alpha_\Delta + \alpha_g + \gamma + \alpha_\rho$。

本次存档的最终版本

$$\boxed{r_{\mathrm{new}}(U, N) = \frac{U}{4}\sqrt{\frac{\kappa(N+1)}{K(m+1)\alpha_g}}.} \tag{28}$$

直接替换旧半径；总预算恢复为 $\alpha_\Delta + \alpha_g + \gamma$。本式未使用 variance cap $1/4$ 或 $\rho^2/4$，有效性直接来自第 4 页的归一化二阶矩证明。

改善幅度与边界

相对于未截断、未使用 disagreement 的半径 $\frac{U}{4}\sqrt{\kappa/(K\alpha_g)}$，新版恰好乘以 $\sqrt{\widetilde{\rho}}$。例如 $\widetilde{\rho} = 0.2$ 时，**波动项**降至原来的 44.7%；曲率项不变。

这不是对所有参数都优于 Bennett 或其旧版最小值的结论：新版对 α_g 的依赖为 $\alpha_g^{-1/2}$。**不能未经证明，将新版随机半径与其他半径事后取最小值并沿用同一预算。** 同样，不能把 $\widetilde{\rho}$ 当成置信上界，用它给整个误差界封顶，或再给曲率项乘上 $\widetilde{\rho}$。

5 完整保证与实验修改

保留目标、估计量和 τ 校准；替换 reference 半径并重算结果

完整的 false-certification 保证

令 $\mathcal{C}$ 表示式 (5) 成立，即程序给出方向一致的认证。若第 2–3 页条件成立，paired summand 方差非零，且 paired CLT 和标准误一致性成立，则固定 K、$m, n \to \infty$ 时，

$$\limsup_{m,n\to\infty} \mathbb{P}\{\mathcal{C} \text{ 且 } \Delta_{\widehat{R}}\Delta^* \le 0\} \le \alpha_\Delta + \alpha_g + \gamma. \tag{29}$$

这是对随机 reference panel 的**联合误认证概率**的控制；不解释为条件于“抽中的 panel 已经不可靠”之后仍有相同的错误率。

证明。 若 $\Delta_{\widehat{R}}\Delta^* \le 0$，则由 $\Delta^* = \Delta_{\widehat{R}} + 2g_{\widehat{R}}$ 得 $|\Delta_{\widehat{R}}| \le 2|g_{\widehat{R}}|$。在 paired 区间覆盖及式 (24) 对应界同时成立时，

$$|\widehat{\Delta}_{\widehat{R}}| - t_{m-1,1-\alpha_\Delta/2}\widehat{\mathsf{se}} \le |\Delta_{\widehat{R}}| \le 2|g_{\widehat{R}}| \le 2a(U) + 2r_{\mathsf{new}}(U,N), \tag{30}$$

因此不会错误认证。对 item 区间失败、reference 浓缩失败及 τ 校准失败作 union bound 即得结论。**三类失败事件之间无需独立。**

具体修改清单

1. **保持比较对象。** $\hat{Y}_A$ 与 Y_B 为二元输出；$\hat{\mu}_R$ 与 μ^* 为概率 reference。沿用已冻结的阈值和样本划分。
2. **保持 U 的计算。** 继续在 D_2 上使用 signed logit contrasts、$\widehat{\Omega}$ 和下侧卡方分位数；保留相同 κ。
3. **在 D_1 新增一个计数。** 计算 N 及 $(N+1)/(m+1)$；$\widehat{\Delta}_{\widehat{R}}$ 和 paired standard error 的计算不改。
4. **替换 RHS 并重算结果。** 使用式 (5)，重新计算拒绝率和认证结论。旧版实验结果不能直接作为新版结果。
5. **固定误差预算。** 沿用或预先指定 $\alpha_\Delta + \alpha_g + \gamma \le \alpha_{\text{total}}$。若原实现曾为 ρ_U 分配 α_ρ，现可在运行最终检验前重新分配；不根据最终拒绝结果调预算。

解释结果时保留的限定

新界主要压低 reference 抽样波动项；曲率项 $2a(U)$ 不随 K 消失，也未因此缩小。若 $2a(U)$ 本身已经超过左侧证据量，本次改动不足以产生拒绝。第 4 页的浓缩结论是有限样本的；**整个检验仍是原框架下的渐近保证。**

来源与版本范围：以会话中已修订的 Bernoulli Task 2（阈值后的模型输出、概率 reference）为对象。旧 τ 校准及 Bernstein 公式对应 `Bernoulli_version_Sept(4).pdf` 第 3–5 节；三个 logit 假设对应 2026-10-04 上传截图。本笔记独立列出最新推导，取代本次讨论中旧的 reference 半径；不修改此前 Task 1 的说明。